

Práctica M17-CD

Caso aplicativo del Business Science Problem Framework (BSPF) y práctica de visualización de datos en Orange
Jorge Pecina

Explicación de los siete pasos del BSPF (caso de fuga de clientes del artículo)

El artículo desarrolla un caso hipotético de fuga de clientes ("customer churn"), donde una empresa está perdiendo clientes frente a la competencia. A continuación explico, con mis propias palabras, en qué consiste cada uno de los siete pasos del framework aplicados a ese caso:

1. Ver el negocio como una máquina. Consiste en identificar qué áreas del negocio están involucradas en el problema, definir cuál es el objetivo que se persigue, y registrar qué está pasando en la realidad. En el caso del artículo, esto significa reconocer que el problema ocurre entre el área de Ventas y el Cliente, que el objetivo es mantenerlo satisfecho, y que el resultado observado es una pérdida gradual de clientes que le cuesta a la empresa 500 mil dólares al año.

2. Entender los factores (drivers). Aquí se investiga si el objetivo se está cumpliendo, se resume lo que se está observando, y se plantea una hipótesis de qué lo está causando, apoyándose en personas que conocen bien el proceso. En el caso, se detecta que los clientes se van porque la competencia entrega más rápido, y se plantea que ese tiempo de entrega depende de los proveedores, el inventario disponible, el personal y el proceso de programación.

3. Medir los factores. Una vez identificados los posibles factores, se recolectan los datos relacionados con ellos y se construyen indicadores (KPIs) que permitan medirlos de forma objetiva. En el ejemplo se definieron indicadores como el tiempo de entrega propio y el de la competencia, el porcentaje de disponibilidad de inventario, y la rotación de personal.

4. Descubrir problemas y oportunidades. En este paso se compara el desempeño real contra los KPIs definidos, para señalar en qué puntos específicos está el problema. En el caso se encuentra que el tiempo de entrega propio (6 semanas) es mucho mayor al de la competencia (2 semanas), lo cual explica gran parte de la pérdida de clientes, mientras que otros factores (como el inventario o el personal) no resultaron ser la causa principal.

5. Codificar algoritmos de decisión. Consiste en desarrollar modelos que expliquen o predigan el problema, optimizar las decisiones para maximizar el beneficio, y construir recomendaciones basadas en esos modelos. En el artículo se sugiere usar herramientas de aprendizaje automático para predecir el riesgo de fuga de cada cliente y, a partir de ahí, recomendar una acción concreta.

6. Medir los resultados. Una vez implementado el modelo o la solución, se le da seguimiento en el tiempo para confirmar si realmente está funcionando. En el caso del artículo se muestra cómo, después de la implementación, la disponibilidad de inventario mejora y la tasa de pérdida de clientes disminuye.

7. Reportar el impacto financiero. Por último, se traduce el resultado obtenido a términos monetarios y se comunica a quienes toman las decisiones en la empresa. En lugar de decir simplemente que se "salvaron" cierto número de clientes, se reporta el equivalente en ingresos que se dejaron de perder, que es el lenguaje que en realidad le importa a la dirección de la empresa.

Aplicabilidad a mi entorno laboral


Considero que el framework sí es aplicable a Vertex Automation, la empresa que dirijo, dedicada a la automatización remota de ranchos y propiedades. El paralelismo con el caso del artículo es bastante directo: así como en el ejemplo los clientes se iban por un tiempo de entrega lento, en mi caso podríamos estar perdiendo confianza de los clientes por fallas intermitentes en portones, luces o cámaras que no se detectan a tiempo. Siguiendo el mismo orden de pasos, primero identificaría que la interacción relevante es entre el área de soporte técnico y el cliente, con el objetivo de mantener el sistema funcionando de forma confiable. Después investigaría qué tanto están fallando los equipos y plantearía, junto con quien instala los sistemas en campo, qué factores podrían estar generando esas fallas (conectividad rural, antigüedad del equipo, firmware, entre otros). A partir de ahí mediría esos factores con datos que ya generan los propios dispositivos, encontraría en cuáles puntos concretos está el problema, y finalmente podría desarrollar un modelo que anticipe fallas, similar al que planteé en una práctica anterior de este módulo. Lo que más rescato del framework para mi caso es el último paso: reportar el resultado en términos financieros, algo que hasta ahora no había considerado de forma explícita, y que sería útil para justificar frente a mí mismo, o ante un futuro socio, si vale la pena invertir tiempo en este tipo de análisis.

Visualizaciones en Orange sobre la base heart_disease.tab

Para esta parte utilicé la base de datos de muestra "heart_disease.tab" disponible en Orange, que contiene información clínica de pacientes (edad, sexo, tipo de dolor de pecho, colesterol, entre otras variables) junto con el diagnóstico de presencia o ausencia de enfermedad cardíaca. A continuación presento tres tipos de gráfico de la sección "Visualize" que no se vieron en el módulo, aplicando distintas condiciones sobre las variables del dataset.

1. Violin Plot — Colesterol según diagnóstico

Condición aplicada: se colorea por la variable "Diagnosis" (con/sin enfermedad) y se elige "Cholesterol" como variable numérica a graficar.




Uso práctico: a diferencia de un boxplot simple, el violin plot muestra la forma completa de la distribución, no solo los cuartiles. En este caso permite notar que el grupo con enfermedad cardíaca tiende a concentrarse en niveles de colesterol más altos, lo cual sería útil para un médico o una aseguradora que quiera identificar de forma visual, y no solo con un

promedio, en qué rango de colesterol conviene poner mayor atención preventiva.

2. Mosaic Display — Tipo de dolor de pecho vs. diagnóstico


Condición aplicada: se cruzan dos variables categóricas, "Chest Pain Type" en el eje horizontal (con el ancho de cada barra proporcional a cuántos pacientes hay en esa categoría) y "Diagnosis" como color dentro de cada barra.



Uso práctico: este gráfico permite ver, de un vistazo, en qué categoría de dolor de pecho se concentra proporcionalmente más el diagnóstico positivo. Llama la atención que la categoría "Asintomático" es la que muestra mayor proporción de enfermedad, lo cual sería un hallazgo relevante para priorizar revisión médica incluso en pacientes que no reportan dolor evidente.

3. Sieve Diagram — Sexo vs. diagnóstico

Condición aplicada: se cruzan las variables "Sex" y "Diagnosis"; el tamaño de cada celda es proporcional a los casos observados, y el color indica si esa combinación aparece más o menos veces de lo que se esperaría si ambas variables fueran independientes entre sí.



Uso práctico: este tipo de gráfico es particularmente útil cuando se quiere confirmar (o descartar) si dos variables categóricas están realmente relacionadas, más allá de la simple intuición. En este caso ayuda a visualizar que el diagnóstico positivo aparece con más frecuencia de la esperada en hombres, lo cual podría orientar campañas de detección temprana dirigidas específicamente a ese grupo.